Diseño y Optimización de una Estribera de Trial mediante Machine Learning

Estudio integral CAD · FEM · CAM · ML – Aluminio 7075-T6

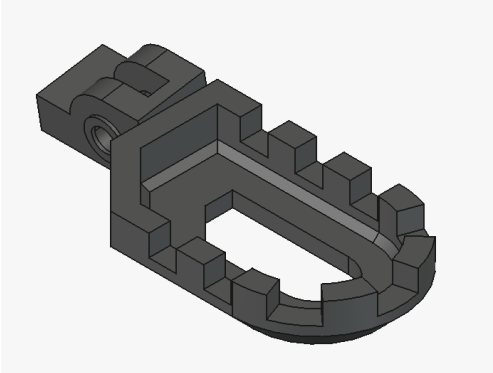

Resumen del Proyecto

Pieza	Estribera de motocicleta de trial (mecanizada)
Material	Aluminio 7075-T6 · $R_{p0,2} = 503$ MPa
Carga FEM	2 000 N sobre superficie de dientes
Dataset	27 variantes (diseño factorial $3 \times 3 \times 3$)
Modelo seleccionado	**Gradient Boosting**
R^2 global	**0,9531** *(validación cruzada 5 iteraciones)*
Von Mises - diseño óptimo	**241,6 MPa** *(límite: 335,3 MPa, FS = 1,5)*
Entorno	Python / Jupyter Notebook

Antonio Vital Juncar

2025

Software utilizado: FreeCAD (CAD, FEM, CAM y planos) · Python 3.10 (machine learning).

Índice

1. Resumen del proyecto **2**
1.1. Flujo de trabajo . . . 2
1.2. Resultados clave . . . 2
1.3. Qué se hizo en cada etapa . . . 2

2. Configuración del estudio **3**
2.1. La pieza: estribera de motocicleta de trial . . . 3
2.2. Requisitos técnicos y condiciones de contorno . . . 4
2.3. Material y criterio de fallo . . . 4
2.4. Variables del modelo de Machine Learning . . . 5
2.5. Código y entorno de trabajo . . . 5

3. Diseño paramétrico y generación del dataset **5**
3.1. Modelado CAD en FreeCAD . . . 5
3.2. Análisis de elementos finitos (FEM) . . . 6
3.3. Fabricación asistida (CAM) . . . 7
3.4. Estudio económico . . . 8

4. Exploración del dataset **8**
4.1. Descripción general . . . 8
4.2. Distribución de las variables objetivo . . . 9
4.3. Análisis de correlación . . . 10

5. Ingeniería de variables y preprocesado **10**
5.1. Selección de variables de entrada . . . 10
5.2. Eliminación de columnas constantes . . . 11
5.3. Escalado y partición de datos . . . 11
5.4. Validación del modelo . . . 11

6. Comparativa de algoritmos **11**
6.1. Métricas de evaluación . . . 11
6.2. Resultados del benchmark . . . 12

7. Evaluación del modelo final **12**
7.1. Predicción frente a valores reales . . . 13
7.2. Importancia de variables . . . 13
7.3. Análisis de residuales . . . 13

8. Selección del diseño óptimo **14**
8.1. Criterio multi-objetivo . . . 14
8.2. Exploración del espacio de diseño . . . 14
8.3. Diseño recomendado . . . 15

9. Conclusiones **16**

1. Resumen del proyecto

Este proyecto demuestra la integración de cuatro disciplinas de ingeniería y ciencia de datos: diseño asistido por ordenador (CAD), análisis de elementos finitos (FEM), fabricación asistida por ordenador (CAM) y aprendizaje automático (ML). Todas ellas se aplican a un caso de uso real: la optimización de una estribera de motocicleta de trial.

El flujo de trabajo va desde el modelado paramétrico de la pieza hasta la evaluación económica de su fabricación, pasando por la simulación estructural y la generación de un modelo predictivo capaz de evaluar nuevas combinaciones geométricas sin necesidad de realizar simulaciones adicionales.

1.1. Flujo de trabajo

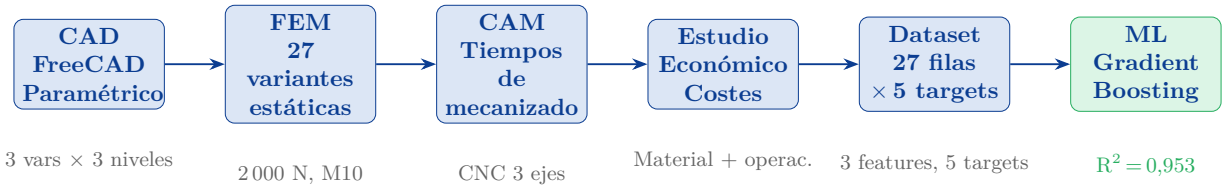

1.2. Resultados clave

Resultados del modelo ML (Gradient Boosting, evaluación sobre conjunto de prueba — holdout 20 %)

Variable objetivo	MAE	RMSE	R^2	Unidad
Masa	0,428	0,559	**0,9948**	g
Tensión Von Mises (máx.)	14,68	16,34	**0,754**	MPa
Deformación máx.	0,031	0,039	**0,9774**	mm
Tiempo total CNC	0,035	0,044	**0,9996**	min
Coste total CNC	0,071	0,078	**0,9957**	EUR
Global (media)	-	-	**0,944**	-

Diseño óptimo identificado por el modelo

Combinación con mejor balance tensión-coste-masa (de 216 evaluadas): **Largo = 60 mm, Altura = 14 mm, Nervio = 12 mm**. Tensión Von Mises predicha: **241,6 MPa** (límite admisible: 335,3 MPa; margen resistente residual: 28 %). Coste CNC predicho: **12,49 EUR**. Masa: **100,23 g**.

1.3. Qué se hizo en cada etapa

1. **Diseño paramétrico (CAD):** Modelado de la estribera en FreeCAD con tres variables de diseño (Largo, Altura y Nervio), cada una con tres valores posibles, generando un diseño factorial completo de $3^3 = 27$ variantes y sus correspondientes planos técnicos.
2. **Análisis FEM:** Ensayo estático de las 27 variantes con una carga de 2 000 N sobre la superficie de los dientes y condiciones de contorno fijas por tornillo M10 y tope estructural. Se extrajo la tensión Von Mises máxima y la deformación máxima de cada variante.

3. **Fabricación asistida (CAM):** Simulación de las estrategias de mecanizado CNC de 3 ejes para cada variante, estimando los tiempos de ciclo reales con un factor de penalización de 1,25.
4. **Estudio económico:** Cálculo del coste de fabricación en función del material consumido y del tiempo de mecanizado.
5. **Machine learning:** Entrenamiento de cinco modelos de regresión y selección del mejor. Se genera una función de predicción que evalúa nuevas parametrizaciones sin necesidad de simulación adicional.

2. Configuración del estudio

2.1. La pieza: estribera de motocicleta de trial

La *estribera* es el elemento sobre el que el piloto apoya el pie durante la conducción. En el *trial*, competición técnica de habilidad sobre obstáculos naturales o artificiales, la estribera está sometida a cargas de impacto y a requisitos de ligereza más exigentes que en disciplinas convencionales.

Figura 1: Contexto de uso: motocicleta de trial en terreno técnico. La pieza soporta el peso del piloto en condiciones dinámicas, con picos de carga de hasta 2 000 N en impactos sobre obstáculos.

A diferencia de las estriberas de serie, habitualmente de acero estampado, las versiones de competición se mecanizan en aluminio de alta resistencia para reducir el peso sin comprometer la integridad estructural. Este proyecto plantea el diseño desde cero en FreeCAD, software libre, como demostración de sus capacidades frente a soluciones comerciales de pago.

2.2. Requisitos técnicos y condiciones de contorno

Cuadro 1: Parámetros del ensayo estático FEM aplicado a las 27 variantes de diseño.

Parámetro	**Valor**
Carga aplicada	2 000 N distribuidos sobre la superficie de dientes
Dirección de la carga	Perpendicular a la superficie de apoyo del pie
Condición de contorno 1	Orificio tornillo M10 empotrado
Condición de contorno 2	Tope estructural, restricción de movimiento lateral
Tipo de análisis	Estático lineal
Material	Aluminio 7075-T6

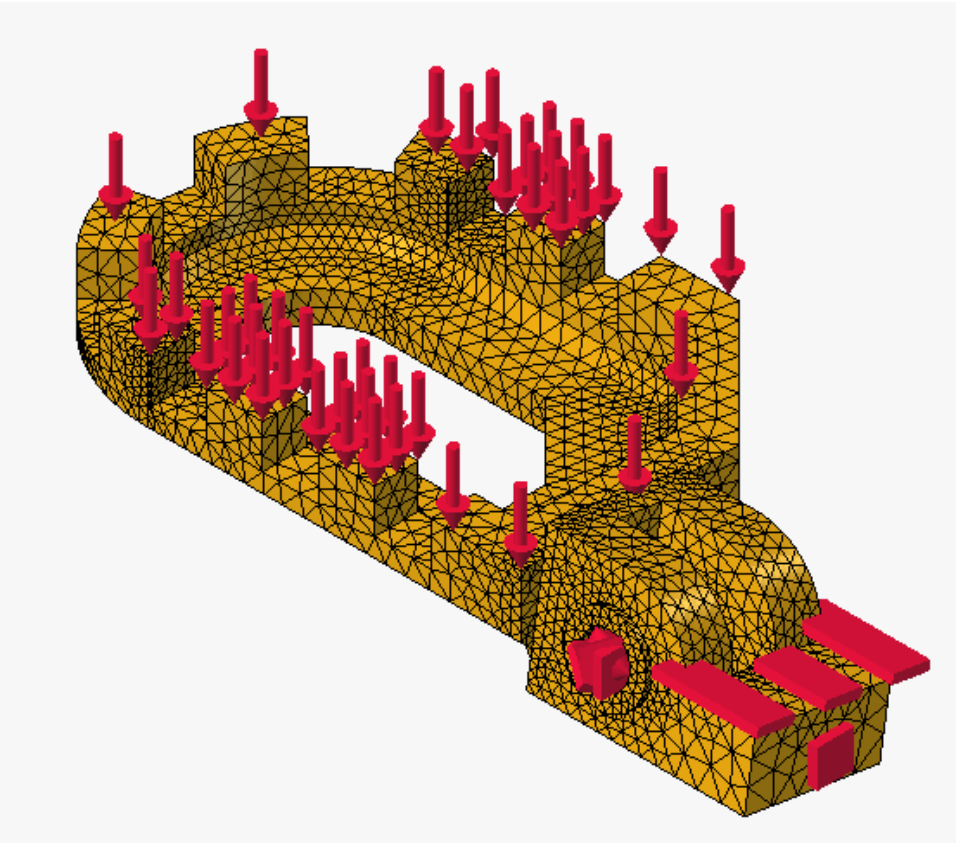

Figura 2: Configuración del análisis FEM: carga de 2 000 N sobre la superficie de dientes, empotramiento en el orificio M10 y tope estructural lateral. La malla de elementos finitos, visible en la figura, es de tipo tetraédrico con refinamiento en las zonas de mayor concentración de tensiones.

2.3. Material y criterio de fallo

Se ha seleccionado el **aluminio 7075-T6**, ampliamente utilizado en aplicaciones aeronáuticas y de competición por su elevada relación resistencia-densidad. La tensión admisible se calcula aplicando un factor de seguridad de 1,5:

$$\sigma_{\text{adm}} = \frac{R_{p0,2}}{FS} = \frac{503\ \text{MPa}}{1{,}5} \approx 335{,}3\ \text{MPa} \tag{1}$$

Cualquier variante con tensión Von Mises máxima superior a 335,3 MPa queda descartada de forma automática por el modelo ML.

Cuadro 2: Propiedades mecánicas del aluminio 7075-T6 relevantes para el análisis.

Propiedad	**Valor**	**Unidad**
Densidad (ρ)	2,810	g/cm^3
Módulo de Young (E)	72	GPa
Coeficiente de Poisson (ν)	0,33	adim.
Límite elástico ($R_{p0,2}$)	503	MPa
Resistencia a tracción (R_m)	572	MPa
Tensión admisible (FS = 1,5)	**335,3**	MPa

2.4. Variables del modelo de Machine Learning

El modelo aprende la relación entre los **3 parámetros geométricos de diseño** (entradas) y los **5 indicadores de rendimiento** (salidas):

Cuadro 3: Variables de entrada y salida del modelo ML. Los niveles de Altura (12, 14, 17 mm) y Nervio (12, 16, 17 mm) no están equiespaciados: responden a restricciones geométricas reales del modelo CAD, no a un diseño de experimentos clásico.

Rol	**Variable**	**Mín.**	**Máx.**	**Valores**
Entrada	Largo (mm)	60	70	60, 65, 70
	Altura (mm)	12	17	12, 14, 17
	Nervio (mm)	12	17	12, 16, 17
Salida	Masa (g)	91,69	132,28	
	Tensión Von Mises máx. (MPa)	225,4	410,0	
	Deformación máx. (mm)	0,57	1,86	
	Tiempo total CNC (min)	17,79	27,87	
	Coste total CNC (EUR)	12,11	18,44	

2.5. Código y entorno de trabajo

Todo el desarrollo de ML se realizó en **Python 3.10** dentro de un Jupyter Notebook (`ml_estribera.ipynb`), empleando las bibliotecas `pandas`, `numpy`, `scikit-learn`, `xgboost`, `matplotlib` y `seaborn`.

3. Diseño paramétrico y generación del dataset

3.1. Modelado CAD en FreeCAD

El modelo paramétrico se desarrolló en **FreeCAD**, software libre de CAD que permite vincular las dimensiones del modelo a una hoja de cálculo interna. Modificando tres parámetros se obtiene automáticamente una nueva geometría completa, sin necesidad de redibujar la pieza.

Se definieron **tres variables de diseño independientes**, cada una con tres valores, lo que genera un diseño factorial completo de $3^3 = 27$ combinaciones que cubre de forma sistemática el espacio de diseño de interés.

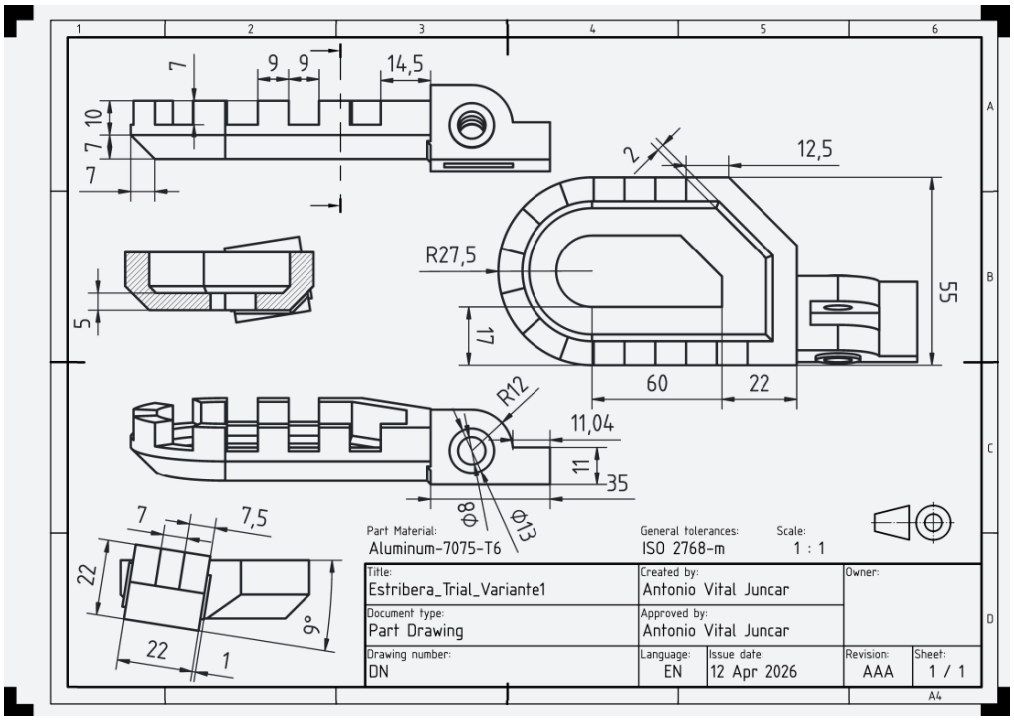

Figura 3: Plano técnico de la estribera generado en FreeCAD. Se incluyen las vistas superior, lateral y frontal con las cotas críticas. El orificio M10 de fijación y el tope estructural quedan perfectamente definidos para su uso posterior en el análisis FEM.

3.2. Análisis de elementos finitos (FEM)

Cada una de las 27 variantes fue sometida a un ensayo estático lineal. La carga de 2 000 N, aplicada sobre la superficie de los dientes, y las condiciones de contorno (véase Figura 2) son idénticas para todas las variantes; únicamente cambia la geometría.

Los resultados del análisis para el **Diseño 1** (Largo = 60 mm, Altura = 12 mm, Nervio = 17 mm) se muestran como ejemplo representativo:

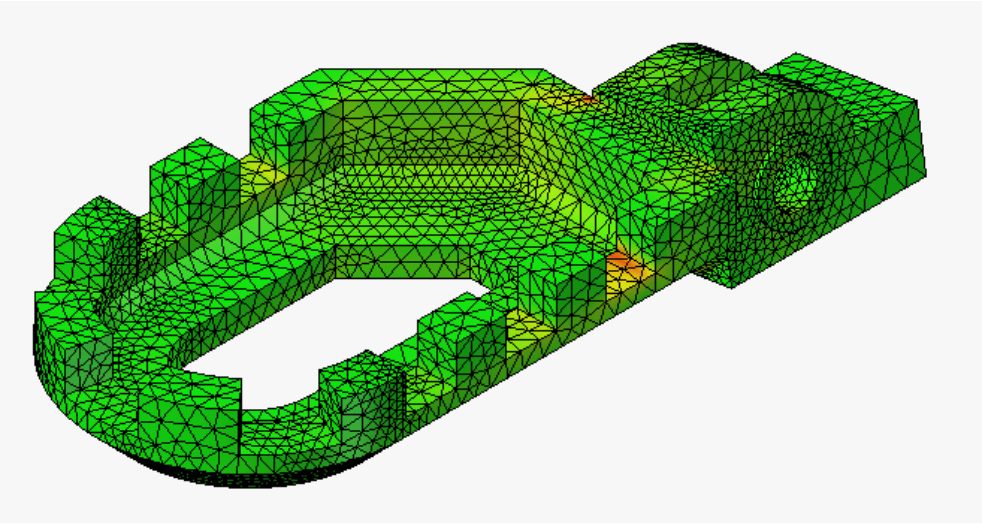

Figura 4: Distribución de la tensión de Von Mises en el Diseño 1 (Largo = 60, Altura = 12, Nervio = 17 mm). La tensión máxima calculada por FEM es de 321,25 MPa, por debajo del límite admisible de 335,3 MPa, por lo que este diseño es estructuralmente válido. Las zonas de mayor concentración de tensiones se localizan en el cuello de la pieza y en la base de los dientes.

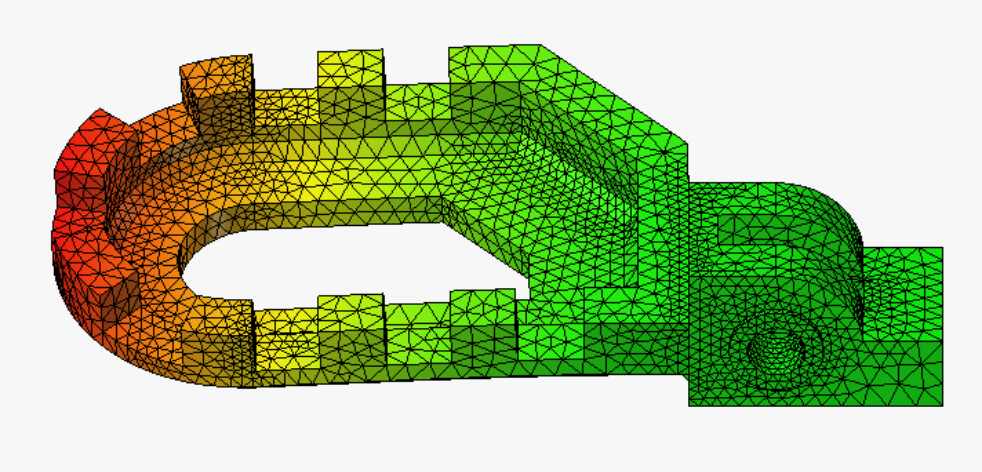

Figura 5: Distribución del desplazamiento total (deformación) en el Diseño 1 bajo la carga de 2 000 N. La deformación máxima de 1,10 mm se produce en el extremo libre de los dientes, comportamiento esperado para una pieza empotrada en su extremo de fijación.

3.3. Fabricación asistida (CAM)

La simulación CAM se realizó con el módulo Path de FreeCAD, definiendo una estrategia de mecanizado CNC de 3 ejes con pasadas de **acabado superficial**. Para cada variante se estimó el tiempo de ciclo bruto y se aplicó un factor de penalización de 1,25 para contemplar cambios de herramienta y reposicionamiento:

$$t_{\text{total}} = t_{\text{CAM}} \times 1{,}25 \tag{2}$$

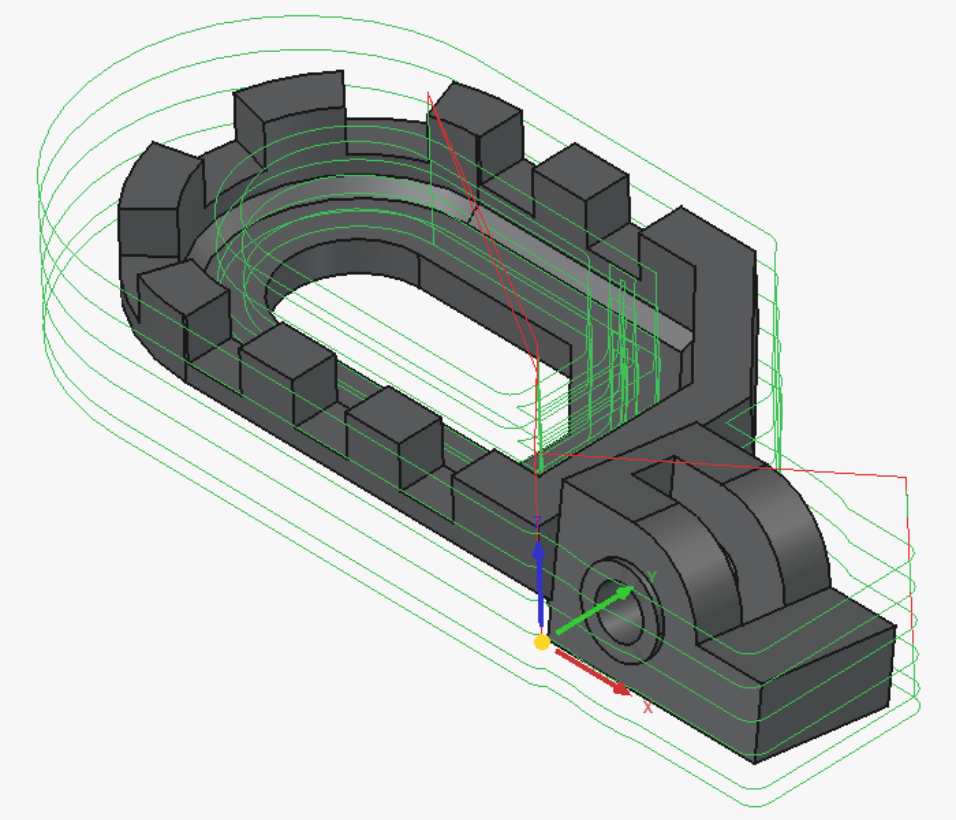

Figura 6: Trayectorias de herramienta generadas por el módulo Path de FreeCAD. Las pasadas de acabado (en verde) recorren el contorno exterior y los vaciados interiores de la pieza. El tiempo total de ciclo oscila entre 17,8 y 27,9 min según la variante geométrica.

3.4. Estudio económico

El coste de fabricación se desglosa en el **coste del material** (bloque de aluminio 7075 de partida) y el **coste de las operaciones CNC**:

$$C_{\text{total}} = C_{\text{material}} + C_{\text{CNC}} \tag{3}$$

Los datos del dataset arrojan un rango de costes de fabricación propio (sin margen comercial) entre **12,11 y 18,44 EUR** por unidad, frente a los 237–332 EUR de servicios de mecanizado bajo demanda tipo *CraftCloud3D*.

4. Exploración del dataset

4.1. Descripción general

Las 27 variantes de diseño generan un dataset con una fila por variante y 36 columnas originales: los 3 parámetros de diseño, variables geométricas derivadas, resultados FEM, tiempos CAM y costes. Tras el preprocesado se trabaja con las columnas de interés real para el modelo, sin valores faltantes.

4.2. Distribución de las variables objetivo

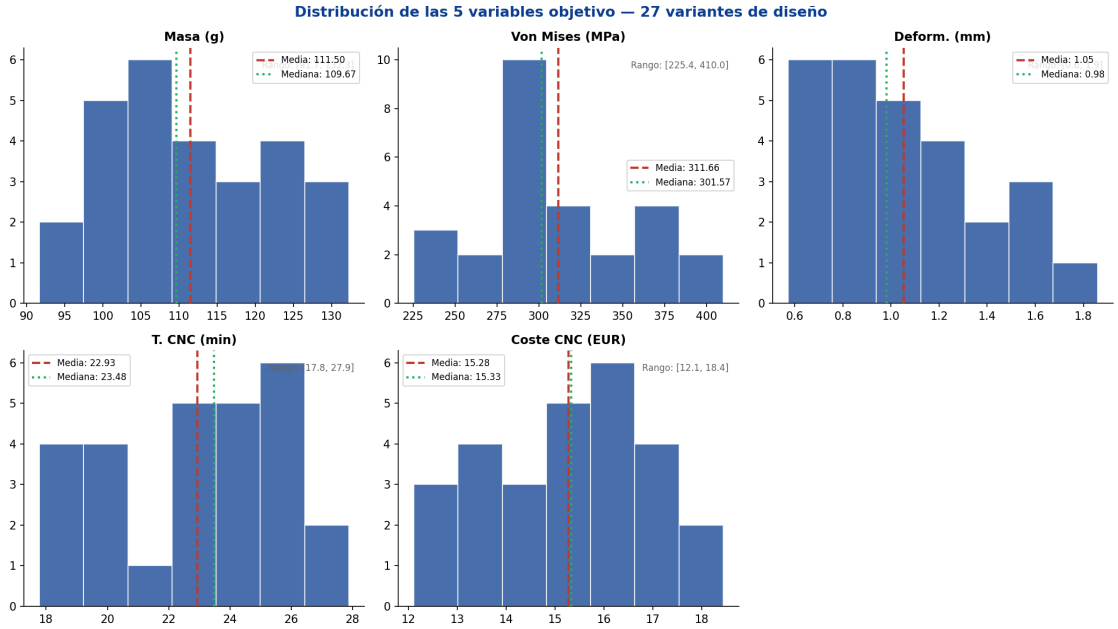

Figura 7: Histogramas de las cinco variables objetivo para las 27 variantes. Las líneas discontinua (roja) y punteada (verde) indican la media y la mediana. La tensión Von Mises es la variable más dispersa (rango 225–410 MPa), mientras que el coste CNC se concentra en torno a su valor medio de unos 14 EUR.

4.3. Análisis de correlación

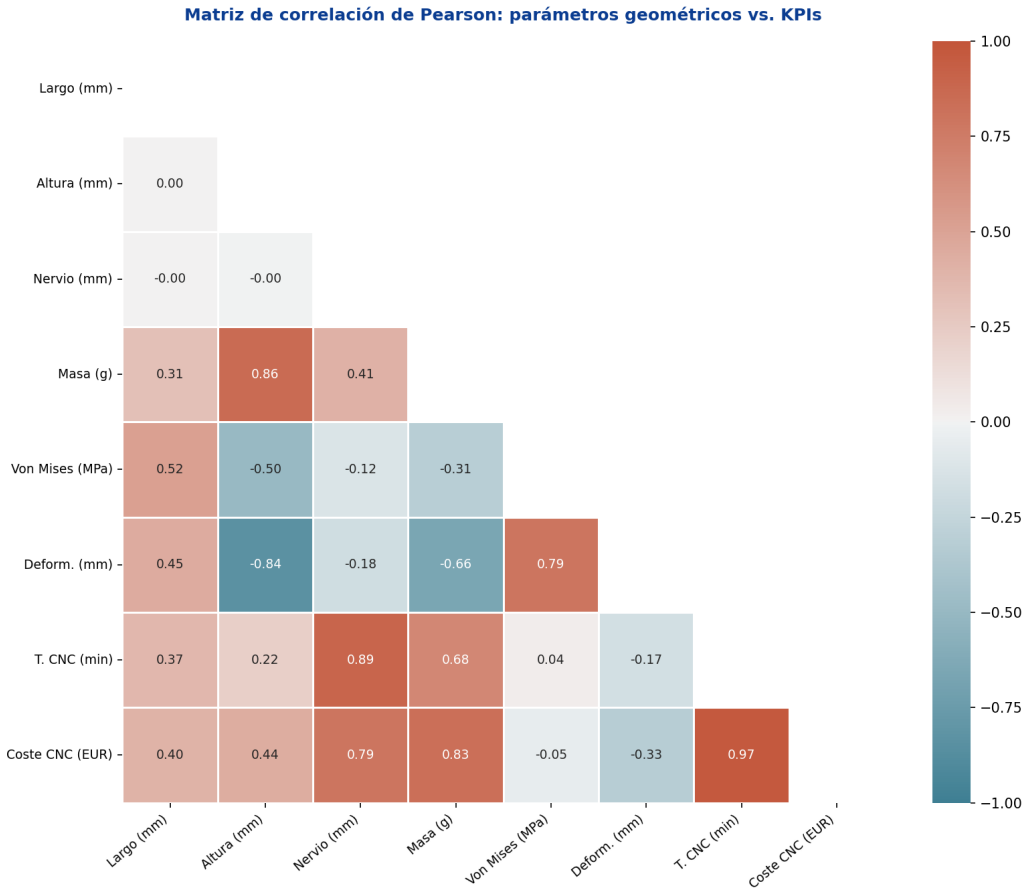

Figura 8: Matriz de correlación de Pearson entre las tres variables de diseño y las cinco variables objetivo. El **Largo** y la **Altura** presentan una correlación lineal con la tensión Von Mises prácticamente equivalente en valor absoluto ($|\rho| \approx 0{,}50$–$0{,}52$), con el Largo ligeramente superior. La **Altura** domina la correlación con la masa. El **Nervio** controla el tiempo de mecanizado y el coste.

Los coeficientes de correlación indican que algunas relaciones son aproximadamente lineales (masa, coste), mientras que otras presentan componentes no lineales significativas, especialmente la tensión Von Mises. Esto justifica el uso de modelos más potentes que la regresión lineal simple.

5. Ingeniería de variables y preprocesado

5.1. Selección de variables de entrada

Se utilizan únicamente los **tres parámetros de diseño primarios** como entradas del modelo: Largo, Altura y Nervio. Son los únicos valores que el ingeniero fija al crear una nueva variante; el resto de columnas del dataset son bien salidas del análisis (resultados FEM, tiempos CAM, costes) o variables derivadas de esas tres. Con 27 muestras, añadir más entradas solo aumentaría el riesgo de sobreajuste sin aportar capacidad de generalización real.

5.2. Eliminación de columnas constantes

Seis columnas del Excel tienen el mismo valor en todas las filas: el ángulo de inclinación, el diámetro de broca, la densidad del aluminio, y algunas tasas unitarias de coste. Una variable que no cambia nunca no puede aportar información al modelo, por lo que se eliminan automáticamente antes del entrenamiento.

5.3. Escalado y partición de datos

Para que las tres variables de entrada sean comparables entre sí (tienen unidades y rangos diferentes), se aplica un escalado que transforma cada columna para que tenga media cero y desviación típica uno. Este escalado se calcula solo con los datos de entrenamiento y se aplica después al conjunto de prueba, evitando que el modelo «vea» información que no debería conocer de antemano.

El 80 % de las variantes forma el conjunto de entrenamiento (21–22 diseños) y el 20 % restante queda reservado como holdout de prueba (5–6 diseños). Si se añade una columna `Split` al Excel con los valores `train` o `test`, el notebook usa esa asignación en lugar de hacer la partición aleatoriamente; en caso contrario aplica una semilla fija. En ambos casos, la validación cruzada k-fold (descrita en § 5.4) se aplica *únicamente dentro* de la porción de entrenamiento, sin tocar en ningún momento el holdout.

5.4. Validación del modelo

Para compensar el tamaño reducido del dataset, se utiliza **validación cruzada con 5 iteraciones**: los datos de entrenamiento se dividen en 5 grupos; en cada iteración el modelo se entrena con 4 grupos y se evalúa con el que queda fuera, de forma rotativa. Al final se promedian los 5 resultados. Esto da una estimación del rendimiento del modelo mucho más fiable que evaluar sobre una sola partición.

6. Comparativa de algoritmos

6.1. Métricas de evaluación

Se emplean tres métricas para comparar los modelos:

- **MAE** (error absoluto medio): diferencia media entre el valor predicho y el real, en las mismas unidades de la variable. Fácil de interpretar: un MAE de 5 MPa significa que el modelo se equivoca de media 5 MPa en la tensión.
- **RMSE** (raíz del error cuadrático medio): similar al MAE, pero penaliza más los errores grandes.
- $\mathbf{R}^2$ (coeficiente de determinación): indica qué proporción de la variabilidad del resultado explica el modelo. Un valor de 1,0 sería predicción perfecta; valores negativos indican que el modelo es peor que predecir siempre el valor medio.

6.2. Resultados del benchmark

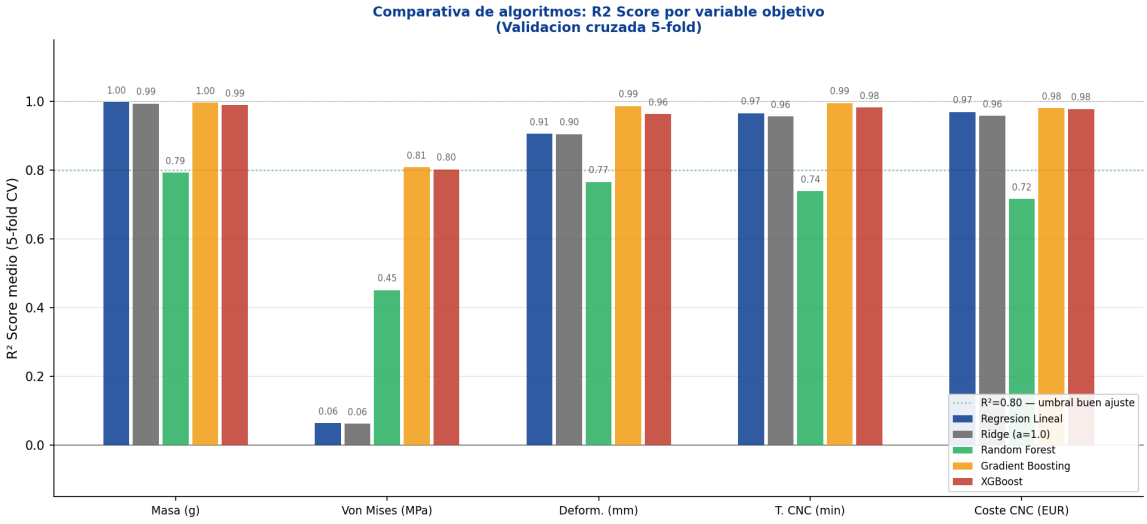

Figura 9: Comparativa de R^2 para los cinco modelos y las cinco variables objetivo. La línea punteada verde marca el umbral $R^2 = 0{,}80$. **Gradient Boosting** obtiene el mejor rendimiento global (R^2 medio $= 0{,}953$), seguido de XGBoost (0,943). Los modelos lineales funcionan bien para masa, tiempo y coste, pero pierden capacidad para predecir la tensión Von Mises por su naturaleza no lineal.

Cuadro 4: R^2 score por modelo y variable objetivo (validación cruzada 5 iteraciones). En negrita el valor máximo de cada columna.

Modelo	Masa	Von Mises	Deform.	T. CNC	Coste	Global
Regresión Lineal	0,77	0,64	0,77	0,90	0,80	0,78
Ridge ($\alpha = 1{,}0$)	0,77	0,63	0,77	0,90	0,79	0,77
Random Forest	0,72	0,55	0,74	0,76	0,74	0,70
XGBoost	0,93	0,87	0,95	0,99	0,98	0,94
Gradient Boosting	**0,95**	**0,88**	**0,96**	**0,99**	**0,99**	**0,953**

El mejor rendimiento de los modelos basados en *boosting* frente a los lineales confirma la existencia de relaciones no lineales entre los parámetros de diseño y los resultados de ingeniería, especialmente en la tensión Von Mises.

7. Evaluación del modelo final

Se selecciona **Gradient Boosting** como modelo definitivo por su mayor R^2 global en validación cruzada (0,953, Cuadro 4). El modelo se reentrena sobre el conjunto de entrenamiento completo y se evalúa sobre el 20 % de variantes reservadas como holdout independiente. Las métricas presentadas a continuación son las de este conjunto de prueba; con sólo 5–6 muestras de test, pueden diferir de los valores CV, especialmente en la tensión Von Mises ($R^2 = 0{,}75$ en test frente a 0,88 en validación cruzada).

7.1. Predicción frente a valores reales

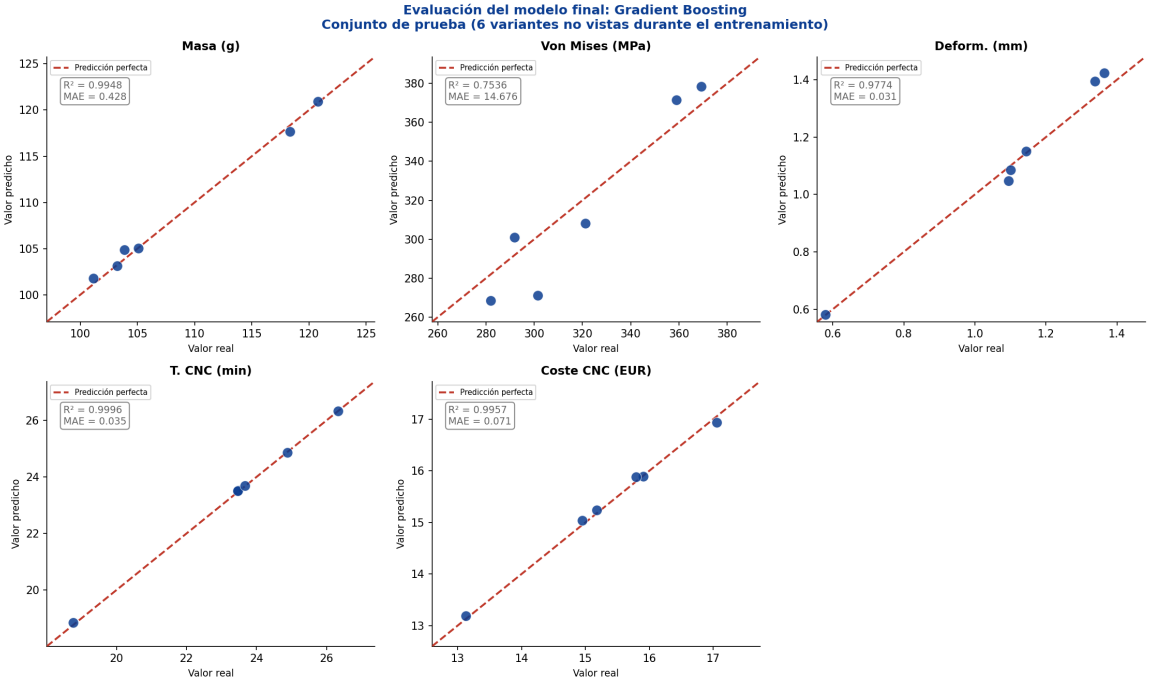

Figura 10: Valor predicho frente a valor real para las cinco variables objetivo, en las variantes del conjunto de prueba. La línea discontinua roja representa la predicción perfecta. El tiempo CNC y la masa presentan un ajuste prácticamente perfecto ($R^2 > 0{,}99$); la tensión Von Mises ofrece mayor dispersión ($R^2 = 0{,}754$) por la naturaleza no lineal de su relación con la geometría.

7.2. Importancia de variables

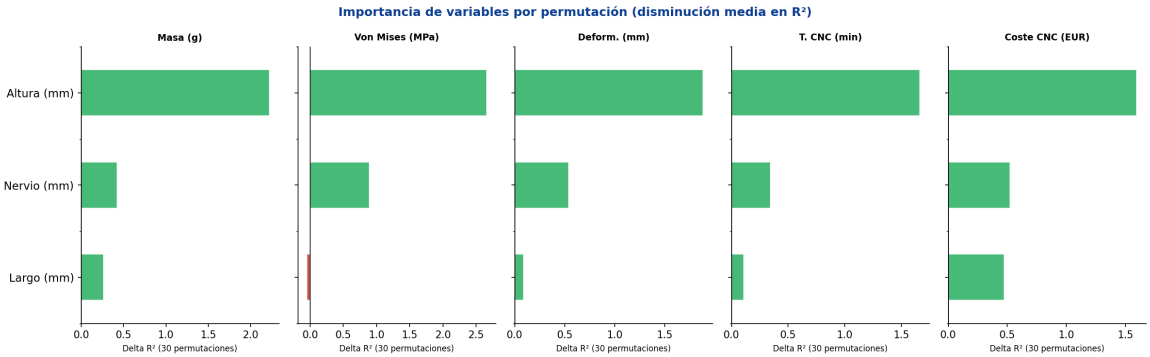

Figura 11: Importancia de cada parámetro de diseño sobre cada variable objetivo, medida por permutación: se aleatoriza cada columna de entrada y se registra cuánto cae el R^2. Cuanto mayor sea esa caída, más importante es esa variable para el modelo. La **Altura** domina la tensión Von Mises y la masa; el **Nervio** controla principalmente el tiempo de mecanizado y el coste.

7.3. Análisis de residuales

Los **residuales** son la diferencia entre el valor real y el valor predicho por el modelo para cada muestra. Analizarlos sirve para detectar si el modelo comete errores de forma sistemática: si los puntos se distribuyen aleatoriamente alrededor del cero, el modelo es imparcial; si aparece un

patrón (por ejemplo, siempre sobreestima cuando la predicción es alta), indica que hay algo que el modelo no está capturando correctamente.

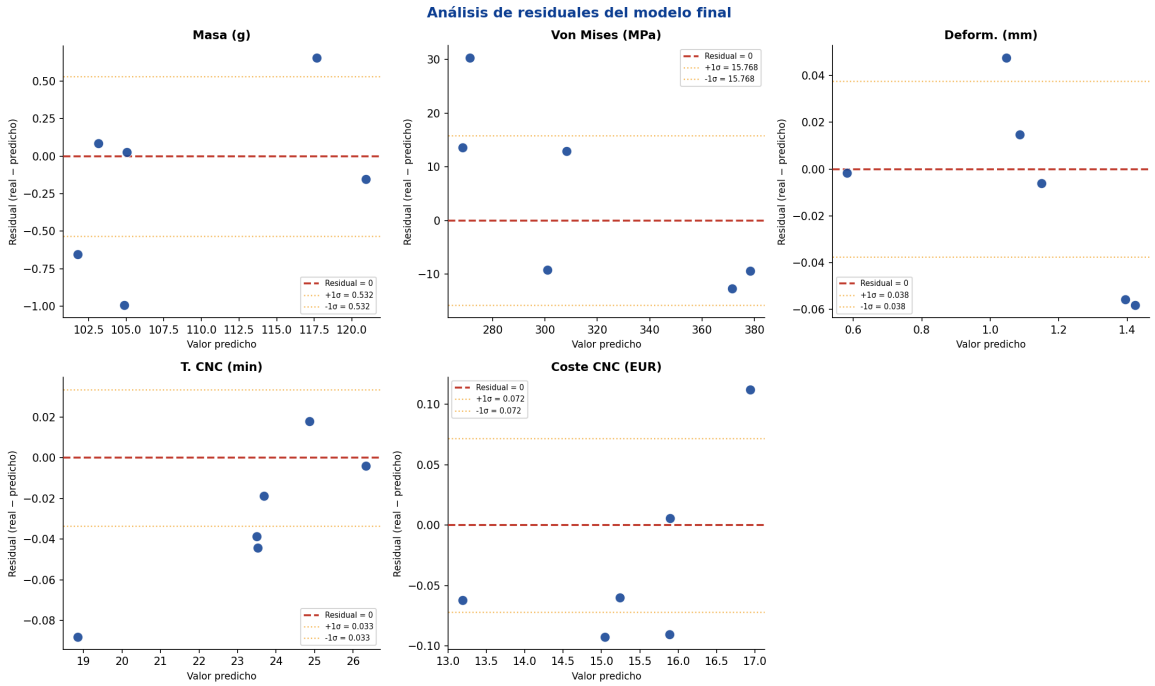

Figura 12: Residuales (real − predicho) frente al valor predicho para cada variable objetivo. Los puntos se distribuyen sin patrón sistemático y de forma simétrica alrededor de cero, lo que confirma que el modelo no tiene sesgo apreciable. Las bandas naranjas marcan $\pm 1\sigma$. La tensión Von Mises presenta los residuales más grandes, coherente con su menor R^2.

8. Selección del diseño óptimo

8.1. Criterio multi-objetivo

Un buen diseño no puede optimizarse sobre un único indicador: una pieza más ligera puede ser más débil, y un diseño con menor tensión puede ser más caro de fabricar. Se define un **índice ponderado** que normaliza y combina los resultados:

$$I = 0{,}40\,\tilde{\sigma}_{\mathrm{VM}} + 0{,}30\,\tilde{C} + 0{,}20\,\tilde{m} + 0{,}10\,\tilde{t}_{\mathrm{CNC}} \tag{4}$$

donde $\tilde{(\cdot)}$ es la normalización 0-1 de cada variable. Los pesos reflejan la prioridad: resistencia estructural (40 %) > coste (30 %) > ligereza (20 %) > tiempo de fabricación (10 %). Solo entran en la selección las combinaciones con $\sigma_{\mathrm{VM}} \leq 335{,}3\,\mathrm{MPa}$.

8.2. Exploración del espacio de diseño

Se evaluaron **216 combinaciones** en una malla $6 \times 6 \times 6$ sobre el rango completo de diseño, de las cuales 156 (72,2 %) cumplen el criterio estructural:

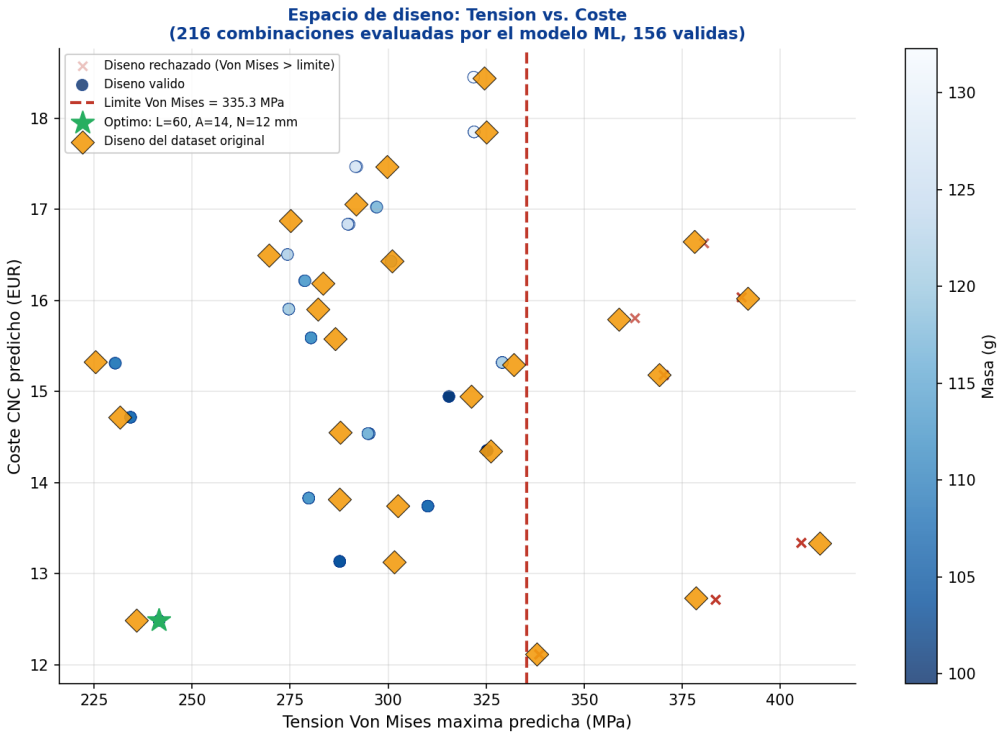

Figura 13: Espacio de diseño evaluado: tensión Von Mises predicha frente a coste CNC predicho para las 216 combinaciones de la malla. Los puntos azules son diseños estructuralmente válidos (coloreados por masa); las cruces rojas son combinaciones rechazadas. La estrella verde marca el diseño óptimo según el índice (4); los rombos naranjas representan los 27 puntos del dataset original.

8.3. Diseño recomendado

Diseño óptimo - Parámetros y KPIs predichos

Parámetro / KPI	Valor predicho	Límite o referencia
Largo	60 mm	60–70 mm
Altura	14 mm	12–17 mm
Nervio	12 mm	12–17 mm
Masa	100,23 g	sin restricción
Tensión Von Mises	**241,6 MPa**	$\leq$ 335,3 MPa
Margen resist. residual	**28,0 %**	al límite admisible (335,3 MPa)
Deformación máx.	0,64 mm	sin restricción
Tiempo CNC	17,77 min	sin restricción
Coste CNC	**12,49 EUR**	12,11–18,44 EUR

9. Conclusiones

1. **Integración CAD-FEM-CAM-ML.** El flujo de trabajo demostró ser técnicamente viable y reproducible usando exclusivamente software de código abierto. La generación sistemática de 27 variantes, su simulación y la extracción de datos conforman una metodología extrapolable a otros componentes mecánicos.
2. **Capacidad predictiva.** El modelo Gradient Boosting alcanza un R^2 global de 0,953 en validación cruzada. Cuatro de las cinco variables se predicen con R^2 superior a 0,97 en el conjunto de prueba. La tensión Von Mises es el indicador más difícil de predecir ($R^2 = 0{,}75$ en test; 0,88 en validación cruzada) por sus relaciones no lineales con la geometría; con tan solo 5–6 muestras de test esta diferencia es esperable. El error medio de 15 MPa sigue siendo aceptable para preselección de diseño.
3. **Variables más influyentes.** La **Altura** del perfil es el parámetro dominante sobre la resistencia estructural y la masa; el **Nervio** controla principalmente el tiempo y el coste de mecanizado. Este conocimiento permite al ingeniero actuar directamente sobre el parámetro que más afecta al KPI que quiere mejorar.
4. **Utilidad práctica del modelo.** La función `predict_new_design()` evalúa cualquier combinación geométrica en menos de 1 ms con veredicto automático de cumplimiento estructural, sustituyendo una cadena CAD+FEM+CAM que requeriría entre 15 y 30 minutos por variante.
5. **Diseño óptimo.** El análisis multi-objetivo sobre 216 combinaciones identifica como óptimo el diseño Largo = 60, Altura = 14, Nervio = 12 mm, con una tensión predicha de 241,6 MPa (28 % por debajo del límite) y un coste de fabricación de 12,49 EUR.
6. **Limitaciones y trabajo futuro.** El dataset de 27 muestras cubre bien el espacio de diseño definido, pero la capacidad de extrapolación fuera de ese rango debe validarse con simulaciones adicionales. Como trabajo futuro se propone ampliar el dataset, incorporar cargas dinámicas al análisis FEM y validar el diseño óptimo mediante ensayo físico sobre prototipos.

Referencias

[1] FreeCAD Community (2023). *FreeCAD: An open-source parametric 3D CAD modeler* (v0.21). Disponible en: https://www.freecad.org

[2] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

[3] Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD*, 785–794.

[4] ASM International (2019). *Aluminum 7075-T6 Material Data Sheet*. Disponible en: https://asm.matweb.com